

Analisis Data Pembangunan Wilayah Indonesia

Proyek Akhir Probabilitas dan Statistika

2026-06-08

Contents

1	Pendahuluan	1
1.1	Load Library	1
2	Memahami Dataset	1
2.1	Membaca Dataset	1
2.2	Struktur Data	1
2.3	Dimensi Dataset	1
2.4	Ringkasan Data	2
2.5	Preview Data	2
2.6	Penjelasan Variabel	3
3	Statistika Deskriptif	4
3.1	Menghitung Statistik Deskriptif	4
3.2	Kuartil	4
3.3	Modus (untuk variabel tahun)	4
3.4	Interpretasi Statistika Deskriptif	4
4	Analisis Missing Value	5
4.1	Identifikasi Missing Value	5
4.2	Dampak Missing Value	5
4.3	Penanganan Missing Value: Median Imputation	6
4.4	Verifikasi Hasil Imputasi	6
5	Analisis Outlier	6
5.1	Metode Deteksi: IQR Method	6
5.2	Baris yang Ditandai Outlier di Dataset	7
5.3	Interpretasi Outlier	7

6	Visualisasi Data	8
6.1	Visualisasi 1: Histogram Distribusi IPM	8
6.2	Visualisasi 2: Boxplot Tingkat Kemiskinan	8
6.3	Visualisasi 3: Scatter Plot IPM vs Kemiskinan	11
6.4	Visualisasi 4: Bar Chart Jumlah Data per Provinsi	11
6.5	Visualisasi 5: Histogram Distribusi Pengangguran	11
6.6	Visualisasi 6 (Bonus): Heatmap Korelasi	14
7	Analisis Probabilitas dan Distribusi Data	14
7.1	Uji Normalitas (Shapiro-Wilk Test)	14
7.2	Probabilitas Kemiskinan di Atas Rata-rata	14
7.3	Probabilitas IPM Tinggi (> 75)	14
7.4	Probabilitas Pengangguran $> 10\%$	15
7.5	Probabilitas Menggunakan Distribusi Normal	15
8	Analisis Korelasi	15
8.1	Matriks Korelasi	15
8.2	Uji Korelasi: IPM dan Kemiskinan	17
8.3	Uji Korelasi: IPM dan Akses Internet	17
8.4	Uji Korelasi: PDRB per Kapita dan Kemiskinan	17
8.5	Panduan Interpretasi Korelasi	18
9	Kesimpulan dan Insight	18
9.1	Ringkasan Hasil Analisis	18
9.2	Temuan Penting	18
9.3	Faktor yang Mempengaruhi Pembangunan Wilayah	19
9.4	Rekomendasi Berbasis Data	19
10	Referensi	19
A	Lampiran: Script R	19
A.1	Load Library dan Membaca Data	19
A.2	Eksplorasi Dataset	20
A.3	Statistika Deskriptif	20
A.4	Analisis Missing Value	21
A.5	Analisis Outlier	22
A.6	Visualisasi Data	23
A.7	Probabilitas dan Distribusi	24
A.8	Analisis Korelasi	25

PROYEK AKHIR

PROBABILITAS DAN STATISTIKA

Analisis Data Pembangunan Wilayah Indonesia

Mata Kuliah : Probabilitas dan Statistika
Program Studi : Teknologi Rekayasa Perangkat Lunak
Tahun Akademik : 2025/2026

Disusun Oleh:

No	Nama	NIM
1	Azzura Mori	J0403251074
2	Azhar Fawwaz Haris	J0403251043
3	Ayyash Syauqi Syahadah	J0403251100
4	Fuad Nizard Attaqi	J0403251086
5	Haidar Hafizh Izzuddin	J0403251031
6	Muhammad Adiyoga Danendra	J0403251063

1 Pendahuluan

Pada proyek akhir ini, kita berperan sebagai analis data yang mengevaluasi kondisi pembangunan wilayah di Indonesia. Dataset yang digunakan berisi berbagai indikator pembangunan seperti tingkat kemiskinan, pengangguran, IPM, PDRB per kapita, akses internet, kualitas infrastruktur, dan indikator sosial lainnya.

Tujuan utama analisis ini adalah:

1. Memahami struktur dan karakteristik dataset
2. Melakukan eksplorasi data menggunakan R
3. Mengidentifikasi missing value dan outlier
4. Melakukan statistika deskriptif
5. Membuat visualisasi data yang informatif
6. Menggunakan konsep probabilitas dan distribusi data
7. Melakukan analisis hubungan antar variabel
8. Menarik kesimpulan berbasis data

1.1 Load Library

2 Memahami Dataset

2.1 Membaca Dataset

2.2 Struktur Data

```
## 'data.frame':    2500 obs. of  13 variables:
## $ wilayah      : chr  "Kabupaten/Kota_1" "Kabupaten/Kota_2" "Kabupaten/Kota_3" "Kabupaten/Kota_4" ...
## $ provinsi     : chr  "Jawa Barat" "Jawa Timur" "Kalimantan Timur" "DKI Jakarta" ...
## $ tahun        : int   2022 2022 2020 2022 2023 2020 2024 2023 2023 2020 ...
## $ pdrb_perkapita : num   3.84e+07 1.66e+08 2.68e+07 1.55e+08 1.99e+08 ...
## $ kemiskinan   : num    19.69  9.68  4.13 20.43 14.39 ...
## $ pengangguran  : num     4.73  4.43  2.99  3.9 12.15 ...
## $ ipm           : num     80.2  55 78.7 73.3 72.9 ...
## $ harapan_hidup : num     75.8  67.8 60.4 69.5 75 ...
## $ rata_lama_sekolah: num     8.41  5.79 13.2 12.28 9.69 ...
## $ akses_internet : num     63.9  66.6 64.7 44.6 52.7 ...
## $ jalan_baik    : num     53.9  34.9 48.6 57.9 65.7 ...
## $ air_bersih    : num     43.1  58.9 90.3 86.2 90.8 ...
## $ catatan_data  : chr   "Normal" "Normal" "Normal" "Normal" ...
```

Dari output `str()` di atas, kita bisa lihat bahwa dataset ini terdiri dari **2500 observasi** dan **13 variabel**. Variabel-variabel tersebut terdiri dari campuran tipe data character (teks) dan numeric (angka).

2.3 Dimensi Dataset

```
## [1] 2500    13
```

Dataset memiliki **2500 baris** (observasi) dan **13 kolom** (variabel).

2.4 Ringkasan Data

```
## wilayah provinsi tahun pdrb_perkapita
## Length:2500 Length:2500 Min. :2020 Min. :1.503e+07
## Class :character Class :character 1st Qu.:2021 1st Qu.:6.962e+07
## Mode :character Mode :character Median :2022 Median :1.373e+08
## Mean :2022 Mean :1.357e+08
## 3rd Qu.:2023 3rd Qu.:1.939e+08
## Max. :2024 Max. :1.775e+09
## NA's :25
## kemiskinan pengangguran ipm harapan_hidup
## Min. : 2.01 Min. : 1.010 Min. :55.01 Min. :60.01
## 1st Qu.: 7.86 1st Qu.: 4.350 1st Qu.:62.52 1st Qu.:64.66
## Median :13.72 Median : 8.230 Median :69.89 Median :69.30
## Mean :13.72 Mean : 8.046 Mean :69.90 Mean :69.13
## 3rd Qu.:19.39 3rd Qu.:11.520 3rd Qu.:77.16 3rd Qu.:73.58
## Max. :67.53 Max. :47.040 Max. :84.99 Max. :77.99
## NA's :24 NA's :25 NA's :25
## rata_lama_sekolah akses_internet jalan_baik air_bersih
## Min. : 5.020 Min. : 0.01 Min. :30.01 Min. :40.03
## 1st Qu.: 7.327 1st Qu.:38.91 1st Qu.:47.40 1st Qu.:54.32
## Median : 9.520 Median :58.09 Median :65.02 Median :69.68
## Mean : 9.581 Mean :58.79 Mean :65.26 Mean :69.76
## 3rd Qu.:11.912 3rd Qu.:78.67 3rd Qu.:83.24 3rd Qu.:85.18
## Max. :14.000 Max. :97.99 Max. :99.95 Max. :99.99
## NA's :25 NA's :25
## catatan_data
## Length:2500
## Class :character
## Mode :character
##
##
##
##
```

2.5 Preview Data

```
## wilayah provinsi tahun pdrb_perkapita kemiskinan
## 1 Kabupaten/Kota_1 Jawa Barat 2022 38403994 19.69
## 2 Kabupaten/Kota_2 Jawa Timur 2022 165582092 9.68
## 3 Kabupaten/Kota_3 Kalimantan Timur 2020 26780948 4.13
## 4 Kabupaten/Kota_4 DKI Jakarta 2022 155034790 20.43
## 5 Kabupaten/Kota_5 Sulawesi Selatan 2023 198834591 14.39
## 6 Kabupaten/Kota_6 Jawa Timur 2020 145702606 17.14
## 7 Kabupaten/Kota_7 Banten 2024 38664542 21.13
## 8 Kabupaten/Kota_8 DKI Jakarta 2023 220135035 16.49
## 9 Kabupaten/Kota_9 Jawa Timur 2023 66855549 2.48
## 10 Kabupaten/Kota_10 Jawa Tengah 2020 131286322 22.64
## pengangguran ipm harapan_hidup rata_lama_sekolah akses_internet jalan_baik
## 1 4.73 80.16 75.75 8.41 63.86 53.86
## 2 4.43 55.05 67.85 5.79 66.61 34.89
## 3 2.99 78.70 60.38 13.20 64.73 48.57
## 4 3.90 73.27 69.49 12.28 44.59 57.88
```

```

## 5      12.15 72.90      75.00      9.69      52.72      65.70
## 6      3.38 65.11      67.04      5.66      55.63      70.12
## 7      6.09 81.88      77.96      8.65      59.08      87.69
## 8      4.27 69.51      63.20     13.93      54.67      82.62
## 9     12.18 75.55      77.18     10.71      20.03      73.23
## 10    12.14 66.32      69.84     10.72      22.27      52.57
##      air_bersih catatan_data
## 1      43.11      Normal
## 2      58.93      Normal
## 3      90.27      Normal
## 4      86.16      Normal
## 5      90.84      Normal
## 6      60.17      Normal
## 7      43.58      Normal
## 8      42.65      Normal
## 9      70.62      Normal
## 10     97.35      Normal

```

2.6 Penjelasan Variabel

Berikut penjelasan arti masing-masing variabel dalam dataset:

No	Variabel	Tipe Data	Penjelasan
1	wilayah	Character	Identitas unik kabupaten/kota
2	provinsi	Character	Provinsi tempat wilayah berada (10 provinsi)
3	tahun	Integer	Tahun pengamatan (2020–2024)
4	pdrb_perkapita	Numeric	PDRB per kapita (Rp), mengukur produktivitas ekonomi daerah
5	kemiskinan	Numeric	Tingkat kemiskinan (%), persentase penduduk miskin
6	pengangguran	Numeric	Tingkat pengangguran (%), persentase penduduk menganggur
7	ipm	Numeric	Indeks Pembangunan Manusia (0–100), gabungan indikator kesehatan, pendidikan, dan standar hidup
8	harapan_hidup	Numeric	Angka harapan hidup (tahun), mencerminkan kualitas kesehatan
9	rata_lama_sekolah	Numeric	Rata-rata lama sekolah (tahun), menunjukkan tingkat pendidikan
10	akses_internet	Numeric	Persentase akses internet (%), indikator konektivitas digital
11	jalan_baik	Numeric	Persentase jalan kondisi baik (%), kualitas infrastruktur
12	air_bersih	Numeric	Persentase akses air bersih (%), indikator kesejahteraan
13	catatan_data	Character	Label: Normal, Missing Value, atau Outlier

3 Statistika Deskriptif

3.1 Menghitung Statistik Deskriptif

Kita menghitung mean, median, standar deviasi, varians, minimum, dan maximum untuk setiap variabel numerik.

Table 1: Statistika Deskriptif Variabel Numerik

	Variabel	Mean	Median	SD	Min	Max
pdrb_perkapita	pdrb_perkapita	135650462.48	137310624.00	89341269.95	15031581.00	1.774545e+09
kemiskinan	kemiskinan	13.72	13.72	6.89	2.01	6.753000e+01
pengangguran	pengangguran	8.05	8.23	4.26	1.01	4.704000e+01
ipm	ipm	69.90	69.89	8.54	55.01	8.499000e+01
harapan_hidup	harapan_hidup	69.13	69.30	5.17	60.01	7.799000e+01
rata_lama_sekolah	rata_lama_sekolah	9.58	9.52	2.63	5.02	1.400000e+01
akses_internet	akses_internet	58.79	58.09	22.82	0.01	9.799000e+01
jalan_baik	jalan_baik	65.26	65.02	20.37	30.01	9.995000e+01
air_bersih	air_bersih	69.76	69.68	17.50	40.03	9.999000e+01

3.2 Kuartil

Table 2: Kuartil Variabel Numerik

Variabel	Min	Q1 (25%)	Median (50%)	Q3 (75%)	Max
PDRB per Kapita (Rp juta)	15.03	69.62	137.31	193.90	1774.55
Kemiskinan (%)	2.01	7.86	13.72	19.39	67.53
Pengangguran (%)	1.01	4.35	8.23	11.52	47.04
IPM	55.01	62.52	69.89	77.16	84.99
Harapan Hidup (Tahun)	60.01	64.66	69.30	73.59	77.99
Rata-rata Lama Sekolah (Tahun)	5.02	7.33	9.52	11.91	14.00
Akses Internet (%)	0.01	38.92	58.09	78.67	97.99
Jalan Baik (%)	30.01	47.39	65.02	83.24	99.95
Air Bersih (%)	40.03	54.32	69.68	85.18	99.99

3.3 Modus (untuk variabel tahun)

Modus variabel tahun: 2020

Modus variabel provinsi: Kalimantan Timur

3.4 Interpretasi Statistika Deskriptif

Variabel dengan nilai rata-rata tertinggi: Variabel `pdrb_perkapita` memiliki rata-rata tertinggi secara absolut (dalam ratusan juta rupiah) karena satuannya berbeda dengan variabel lain yang dalam persen. Kalau kita bandingkan variabel-variabel dalam skala persen saja, `ipm` dan `air_bersih` yang punya rata-rata paling tinggi – ini menunjukkan bahwa rata-rata pembangunan manusia dan akses air bersih di Indonesia cukup baik.

Variabel dengan penyebaran terbesar: Secara absolut, `pdrb_perkapita` memiliki standar deviasi dan varians yang paling besar. Ini menunjukkan adanya **ketimpangan ekonomi** yang signifikan antar wilayah di Indonesia. Ada wilayah yang sangat produktif (PDRB tinggi) dan ada yang masih tertinggal.

Indikasi data tidak normal:

- `pdrb_perkapita`: Selisih antara mean dan median menunjukkan distribusi yang *skewed* (miring), ditambah dengan adanya outlier ekstrem (nilai max sangat jauh dari Q3).
- `kemiskinan` dan `pengangguran`: Keduanya juga memiliki outlier yang menarik distribusi ke kanan.

4 Analisis Missing Value

4.1 Identifikasi Missing Value

Table 3: Jumlah Missing Value per Variabel

Variabel	Jumlah_NA	Persentase
wilayah	0	0.00
provinsi	0	0.00
tahun	0	0.00
pdrb_perkapita	25	1.00
kemiskinan	24	0.96
pengangguran	25	1.00
ipm	25	1.00
harapan_hidup	0	0.00
rata_lama_sekolah	0	0.00
akses_internet	25	1.00
jalan_baik	25	1.00
air_bersih	0	0.00
catatan_data	0	0.00

```
## Total baris dengan label 'Missing Value': 143
```

```
## Total sel (cell) yang NA: 149
```

4.2 Dampak Missing Value

Missing value memiliki beberapa dampak negatif terhadap analisis statistik:

1. **Bias pada hasil statistik:** Jika data yang hilang tidak random (MNAR), maka mean, median, dan statistik lainnya bisa menyimpang dari nilai sebenarnya.
2. **Pengurangan jumlah sampel:** Menghapus baris dengan NA (`na.omit()`) akan mengurangi jumlah data, yang mengurangi kekuatan statistik analisis.
3. **Mengganggu analisis korelasi:** Fungsi `cor()` menghasilkan NA jika ada missing value, sehingga perlu parameter `use = "complete.obs"`.
4. **Visualisasi kurang akurat:** Histogram dan boxplot yang tidak menangani NA bisa menampilkan distribusi yang tidak representatif.

4.3 Penanganan Missing Value: Median Imputation

Kita memilih **median imputation** dengan alasan:

- **Robust terhadap outlier:** Dataset ini mengandung outlier (pdrb_perkapita bisa melebihi 1 miliar), sehingga mean imputation akan terpengaruh oleh nilai ekstrem tersebut. Median tidak terpengaruh.
- **Mempertahankan distribusi asli:** Median imputation lebih menjaga bentuk distribusi data dibandingkan mean imputation.
- **Cocok untuk data non-normal:** Beberapa variabel kita (terutama pdrb_perkapita) tidak berdistribusi normal.
- **Sederhana dan efektif:** Untuk proporsi missing yang relatif kecil (~2% per variabel), median imputation sudah cukup baik.

4.4 Verifikasi Hasil Imputasi

Sisa missing value setelah imputasi:

```
##          wilayah          provinsi          tahun    pdrb_perkapita
##          0              0              0          0
##      kemiskinan    pengangguran          ipm    harapan_hidup
##          0              0              0          0
## rata_lama_sekolah    akses_internet    jalan_baik    air_bersih
##          0              0              0          0
##      catatan_data
##          0
```

Semua missing value berhasil ditangani. Dataset sekarang bersih dari NA.

5 Analisis Outlier

5.1 Metode Deteksi: IQR Method

Outlier dideteksi menggunakan metode **IQR (Interquartile Range)**:

- $Q1$ = Kuartil 1 (persentil ke-25)
- $Q3$ = Kuartil 3 (persentil ke-75)
- $IQR = Q3 - Q1$
- **Batas bawah** = $Q1 - 1.5 \times IQR$
- **Batas atas** = $Q3 + 1.5 \times IQR$

Data yang berada di luar batas bawah atau batas atas dianggap outlier.

Table 4: Jumlah Outlier per Variabel (Metode IQR)

Variabel	Jumlah_Outlier
tahun	0
pdrb_perkapita	5

kemiskinan	5
pengangguran	5
ipm	0
harapan_hidup	0
rata_lama_sekolah	0
akses_internet	0
jalan_baik	0
air_bersih	0

5.2 Baris yang Ditandai Outlier di Dataset

Jumlah baris berlabel 'Outlier': 20

Table 5: Baris Data yang Berlabel Outlier

wilayah	provinsi	tahun	pdrb_perkapita	kemiskinan	pengangguran	akses_internet
Kabupaten/Kota_95	Sumatera Utara	2020	1472419961	12.07	1.79	64.04
Kabupaten/Kota_140	Jawa Barat	2024	180379693	16.83	13.56	2.18
Kabupaten/Kota_150	Sumatera Barat	2023	211496558	12.36	47.04	57.74
Kabupaten/Kota_214	DKI Jakarta	2022	54455331	11.12	34.90	85.19
Kabupaten/Kota_300	DKI Jakarta	2022	114049749	20.56	36.74	34.45
Kabupaten/Kota_315	Jawa Timur	2021	207838734	45.95	1.97	33.74
Kabupaten/Kota_454	Sulawesi Selatan	2024	1474832345	5.82	9.68	50.56
Kabupaten/Kota_656	Kalimantan Timur	2022	1774545027	12.30	1.61	40.82
Kabupaten/Kota_700	DKI Jakarta	2023	37020527	12.44	36.68	56.45
Kabupaten/Kota_871	Banten	2024	98663409	20.98	9.87	0.35
Kabupaten/Kota_1098	DKI Jakarta	2022	65964243	53.30	11.02	22.86
Kabupaten/Kota_1190	Jawa Tengah	2020	1087231959	18.23	3.41	29.76
Kabupaten/Kota_1195	DKI Jakarta	2020	113613456	4.16	13.85	2.99
Kabupaten/Kota_1222	Banten	2020	218464314	67.53	6.29	72.65
Kabupaten/Kota_1289	Jawa Tengah	2022	1012449971	20.65	8.56	84.41
Kabupaten/Kota_1446	Sulawesi Selatan	2020	174088787	47.69	9.24	43.08
Kabupaten/Kota_1467	Sumatera Utara	2022	232179673	7.81	33.19	87.41
Kabupaten/Kota_2017	Sulawesi Selatan	2024	184998519	7.09	5.52	0.01
Kabupaten/Kota_2178	Jawa Timur	2021	160442064	8.52	10.60	0.44
Kabupaten/Kota_2211	Kalimantan Timur	2024	48093259	58.41	5.70	94.97

5.3 Interpretasi Outlier

Berdasarkan analisis IQR dan label `catatan_data`, outlier ditemukan pada variabel:

- **pdrb_perkapita**: Beberapa wilayah memiliki PDRB per kapita yang sangat tinggi (>1 miliar rupiah), jauh di atas rentang normal (~15-250 juta). Ini bisa menunjukkan kesalahan data entry atau wilayah dengan aktivitas ekonomi khusus (pertambangan, industri besar).
- **kemiskinan**: Outlier di atas 40% sangat tidak lazim dan kemungkinan anomali data.
- **pengangguran**: Nilai pengangguran di atas 30% sangat ekstrem dan tidak realistis.
- **akses_internet**: Beberapa wilayah memiliki akses internet mendekati 0%, yang sangat tidak wajar.

Dampak outlier terhadap analisis:

1. Mean menjadi terdistorsi (tertarik ke arah outlier)
2. Standar deviasi dan varians membesar

3. Korelasi antar variabel bisa menyimpang
4. Uji normalitas hampir pasti menolak H_0 jika outlier masih ada

6 Visualisasi Data

6.1 Visualisasi 1: Histogram Distribusi IPM




Figure 1: Distribusi Indeks Pembangunan Manusia (IPM)

Interpretasi: Distribusi IPM mendekati bentuk lonceng (bell-shaped), yang berarti mendekati distribusi normal. Sebagian besar wilayah memiliki IPM di rentang 60–80, dengan puncak frekuensi di sekitar 65–75. Ini menunjukkan bahwa mayoritas wilayah berada pada kategori pembangunan manusia “sedang” hingga “tinggi”.

6.2 Visualisasi 2: Boxplot Tingkat Kemiskinan

Interpretasi: Median kemiskinan berada di sekitar 13.5%. Kotak (IQR) menunjukkan bahwa 50% data berada di rentang ~7.5%–20%. Terdapat beberapa titik outlier di atas 25% yang menandakan adanya wilayah-wilayah dengan kemiskinan sangat tinggi. Distribusi sedikit miring ke kanan (*positively skewed*).




Figure 2: Boxplot Tingkat Kemiskinan




Figure 3: Hubungan IPM dan Kemiskinan

6.3 Visualisasi 3: Scatter Plot IPM vs Kemiskinan

Interpretasi: Scatter plot menunjukkan hubungan antara IPM dan kemiskinan. Garis regresi (merah putus-putus) membantu melihat tren. Dalam data ini, hubungan antara kedua variabel tampak lemah. Secara teori, seharusnya ada korelasi negatif (IPM tinggi = kemiskinan rendah), namun karena data bersifat sintetis, polanya tidak terlalu jelas.

6.4 Visualisasi 4: Bar Chart Jumlah Data per Provinsi




Figure 4: Jumlah Data per Provinsi

Interpretasi: Setiap provinsi memiliki jumlah data yang relatif seimbang (~250 observasi per provinsi). Ini menunjukkan dataset dibuat secara *balanced*, sehingga perbandingan antar provinsi bisa dilakukan secara adil. Terdapat 10 provinsi: Jawa Barat, Jawa Tengah, Jawa Timur, DKI Jakarta, Banten, Sumatera Utara, Sumatera Barat, Kalimantan Timur, Sulawesi Selatan, dan Papua.

6.5 Visualisasi 5: Histogram Distribusi Pengangguran

Interpretasi: Distribusi pengangguran mendekati bentuk merata (*uniform*) pada rentang 1–15%. Terdapat beberapa outlier di atas 15% yang tampak sebagai bar kecil di ujung kanan. Mayoritas wilayah memiliki pengangguran di bawah 15%.




Figure 5: Distribusi Tingkat Pengangguran

Heatmap Korelasi Antar Variabel




Figure 6: Heatmap Korelasi Antar Variabel Numerik

6.6 Visualisasi 6 (Bonus): Heatmap Korelasi

Interpretasi: Heatmap menampilkan kekuatan dan arah korelasi antar variabel numerik. Warna biru menunjukkan korelasi positif, merah menunjukkan korelasi negatif. Nilai mendekati 0 berarti hubungan sangat lemah.

7 Analisis Probabilitas dan Distribusi Data

7.1 Uji Normalitas (Shapiro-Wilk Test)

Kita menguji apakah variabel IPM berdistribusi normal menggunakan Shapiro-Wilk Test.

Hipotesis:

- H_0 : Data berdistribusi normal
- H_1 : Data TIDAK berdistribusi normal
- $\alpha = 0.05$

```
##
## Shapiro-Wilk normality test
##
## data:  sample(data_clean$ipm, 500)
## W = 0.95722, p-value = 7.276e-11

## Keputusan: TOLAK  $H_0$  (p-value = 0 < 0.05)
## Kesimpulan: Data IPM secara statistik TIDAK berdistribusi normal sempurna.
```

Catatan: Shapiro-Wilk Test cenderung menolak H_0 pada sampel besar karena sensitivitasnya tinggi. Meskipun uji formal mungkin menolak normalitas, secara visual (histogram) distribusi IPM cukup mendekati bentuk normal.

7.2 Probabilitas Kemiskinan di Atas Rata-rata

```
## Rata-rata kemiskinan: 13.72 %

## P(kemiskinan > rata-rata) = 0.4944

## Artinya: 49.4 % wilayah memiliki kemiskinan di atas rata-rata.
```

Interpretasi: Sekitar 49.4% wilayah memiliki tingkat kemiskinan di atas rata-rata. Ini masuk akal karena distribusi kemiskinan mendekati simetris, sehingga sekitar setengah data berada di atas rata-rata.

7.3 Probabilitas IPM Tinggi (> 75)

```
## P(IPM > 75) = 0.3188

## Artinya: 31.9 % wilayah memiliki IPM di atas 75 (kategori tinggi).
```

Interpretasi: Hanya sekitar 31.9% wilayah yang memiliki IPM di atas 75 (kategori “tinggi” menurut BPS). Ini berarti mayoritas wilayah masih perlu meningkatkan kualitas pembangunan manusia.

7.4 Probabilitas Pengangguran $> 10\%$

```
## P(pengangguran > 10%) = 0.362
```

```
## Artinya: 36.2 % wilayah memiliki pengangguran di atas 10%.
```

Interpretasi: Sekitar 36.2% wilayah memiliki tingkat pengangguran di atas 10%. Ini cukup signifikan dan menunjukkan bahwa masalah ketenagakerjaan masih menjadi tantangan di banyak daerah.

7.5 Probabilitas Menggunakan Distribusi Normal

Kita juga bisa menghitung probabilitas menggunakan pendekatan distribusi normal (pnorm).

```
## Berdasarkan distribusi normal:
```

```
## P(IPM > 80) = 0.1172
```

```
## Nilai IPM pada persentil ke-90: 80.78
```

8 Analisis Korelasi

8.1 Matriks Korelasi

Table 6: Matriks Korelasi Antar Variabel Numerik

	PDRB	Miskin	Nganggur	IPM	Harapan	Sekolah	Internet	Jalan	Air
PDRB per Kapita (Rp juta)	1.000	-0.005	-0.032	0.011	0.012	-0.003	-0.006	0.035	0.005
Kemiskinan (%)	-0.005	1.000	-0.009	0.020	-0.014	0.002	-0.031	0.020	0.001
Pengangguran (%)	-0.032	-0.009	1.000	0.000	0.001	0.002	0.020	-0.009	0.007
IPM	0.011	0.020	0.000	1.000	0.010	0.018	0.002	0.023	0.023
Harapan Hidup (Thn)	0.012	-0.014	0.001	0.010	1.000	-0.012	0.009	0.006	-0.020
Lama Sekolah (Thn)	-0.003	0.002	0.002	0.018	-0.012	1.000	-0.005	0.049	0.014
Akses Internet (%)	-0.006	-0.031	0.020	0.002	0.009	-0.005	1.000	-0.005	-0.010
Jalan Baik (%)	0.035	0.020	-0.009	0.023	0.006	0.049	-0.005	1.000	0.024
Air Bersih (%)	0.005	0.001	0.007	0.023	-0.020	0.014	-0.010	0.024	1.000

8.2 Uji Korelasi: IPM dan Kemiskinan

```
##
## Pearson's product-moment correlation
##
## data: data_clean$ipm and data_clean$kemiskinan
## t = 0.98096, df = 2498, p-value = 0.3267
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
## -0.01959447 0.05878083
## sample estimates:
## cor
## 0.01962333
```

Interpretasi: Korelasi antara IPM dan kemiskinan sebesar $r = 0.0196$. Secara teori, hubungan ini seharusnya negatif kuat (IPM tinggi berarti kemiskinan rendah). Dalam dataset sintetis ini, korelasi mungkin lemah. P-value ≥ 0.05 menunjukkan hubungan yang tidak signifikan secara statistik.

8.3 Uji Korelasi: IPM dan Akses Internet

```
##
## Pearson's product-moment correlation
##
## data: data_clean$ipm and data_clean$akses_internet
## t = 0.10552, df = 2498, p-value = 0.916
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
## -0.03709453 0.04131056
## sample estimates:
## cor
## 0.002111257
```

Interpretasi: Korelasi antara IPM dan akses internet sebesar $r = 0.0021$. Secara teori, akses internet yang lebih baik seharusnya berkaitan dengan pembangunan manusia yang lebih tinggi.

8.4 Uji Korelasi: PDRB per Kapita dan Kemiskinan

```
##
## Pearson's product-moment correlation
##
## data: data_clean$pdrb_perkapita and data_clean$kemiskinan
## t = -0.2342, df = 2498, p-value = 0.8148
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
## -0.04388052 0.03452320
## sample estimates:
## cor
## -0.004685858
```

Interpretasi: Korelasi antara PDRB per kapita dan kemiskinan sebesar $r = -0.0047$. Secara teori, daerah dengan produktivitas ekonomi yang lebih tinggi seharusnya memiliki tingkat kemiskinan yang lebih rendah.

8.5 Panduan Interpretasi Korelasi

Nilai r	Kekuatan Hubungan
0.00 – 0.19	Sangat lemah
0.20 – 0.39	Lemah
0.40 – 0.59	Sedang
0.60 – 0.79	Kuat
0.80 – 1.00	Sangat kuat

Tanda positif (+) = hubungan searah, tanda negatif (-) = hubungan berlawanan arah.

9 Kesimpulan dan Insight

9.1 Ringkasan Hasil Analisis

1. **Dataset** terdiri dari 2500 observasi dari 10 provinsi, mencakup periode 2020–2024, dengan 13 variabel tentang aspek ekonomi, sosial, dan infrastruktur.
2. **IPM rata-rata** sekitar 69.9, menunjukkan pembangunan manusia Indonesia berada pada kategori “sedang”.
3. **Kemiskinan rata-rata** sekitar 13.7%, dengan distribusi yang cukup merata.
4. **Missing value** ditemukan pada beberapa variabel numerik dan telah ditangani dengan median imputation.
5. **Outlier** terdeteksi pada `pdrb_perkapita` (>1 miliar), `kemiskinan` (>40%), `pengangguran` (>30%), dan `akses_internet` (mendekati 0%).
6. **Distribusi IPM** mendekati normal, sementara `pdrb_perkapita` memiliki distribusi *right-skewed*.
7. **Korelasi** antar variabel bervariasi; hubungan terkuat dan terlemah dapat dilihat dari matriks korelasi di atas.

9.2 Temuan Penting

- **Ketimpangan Ekonomi:** PDRB per kapita memiliki rentang yang sangat lebar, menunjukkan ketimpangan ekonomi signifikan antar wilayah.
- **Digital Divide:** Akses internet sangat bervariasi (hampir 0% hingga 98%), menunjukkan kesenjangan digital yang besar.
- **Mayoritas IPM Sedang:** Sekitar 68% wilayah masih memiliki IPM di bawah 75, menandakan pembangunan manusia belum merata.
- **Masalah Ketenagakerjaan:** Sekitar 36% wilayah memiliki pengangguran >10%.

9.3 Faktor yang Mempengaruhi Pembangunan Wilayah

1. **Faktor Ekonomi** (`pdrb_perkapita`): Produktivitas ekonomi tinggi memungkinkan lebih banyak sumber daya untuk pembangunan.
2. **Faktor Pendidikan** (`rata_lama_sekolah`, `ipm`): Pendidikan yang lebih baik meningkatkan kualitas SDM.
3. **Faktor Kesehatan** (`harapan_hidup`): Kesehatan masyarakat mendukung produktivitas.
4. **Faktor Infrastruktur** (`jalan_baik`, `akses_internet`, `air_bersih`): Infrastruktur yang memadai merupakan fondasi pembangunan.
5. **Faktor Sosial** (`kemiskinan`, `pengangguran`): Kemiskinan dan pengangguran rendah menunjukkan pembangunan yang inklusif.

9.4 Rekomendasi Berbasis Data

1. **Fokus pada wilayah IPM rendah (< 60)**: Alokasi lebih banyak sumber daya untuk meningkatkan pendidikan dan kesehatan.
 2. **Pemerataan akses internet**: Prioritaskan infrastruktur digital di wilayah dengan akses rendah.
 3. **Program pengentasan kemiskinan yang ditargetkan**: Perluas bantuan sosial dan pemberdayaan ekonomi.
 4. **Penanganan pengangguran**: Kembangkan program pelatihan kerja dan dukungan UMKM.
 5. **Peningkatan kualitas data**: Perbaiki sistem pengumpulan data untuk mengurangi missing value dan error.
-

10 Referensi

1. Walpole, R. E., Myers, R. H., Myers, S. L., & Ye, K. (2012). *Probability & Statistics for Engineers & Scientists* (9th ed.). Pearson Education.
 2. Wickham, H. (2016). *ggplot2: Elegant Graphics for Data Analysis*. Springer-Verlag New York.
 3. BPS (Badan Pusat Statistik). (2023). *Indeks Pembangunan Manusia 2023*. Jakarta: Badan Pusat Statistik.
 4. Field, A. (2013). *Discovering Statistics Using R*. SAGE Publications.
 5. James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). *An Introduction to Statistical Learning with Applications in R*. Springer.
-

A Lampiran: Script R

Berikut adalah seluruh kode R yang digunakan dalam analisis ini.

A.1 Load Library dan Membaca Data

```
library(ggplot2)
library(dplyr)
library(corrplot)
library(knitr)
library(kableExtra)
```

```
data <- read.csv("../Dataset/pembangunan_wilayah_missing_outlier.csv")
```

A.2 Eksplorasi Dataset

```
str(data)
```

```
dim(data)
```

```
summary(data)
```

```
head(data, 10)
```

A.3 Statistika Deskriptif

```
numeric_data <- data %>% select(where(is.numeric), -tahun)
```

```
deskriptif <- data.frame(
  Variabel = names(numeric_data),
  Mean     = round(sapply(numeric_data, mean, na.rm = TRUE), 2),
  Median   = round(sapply(numeric_data, median, na.rm = TRUE), 2),
  SD       = round(sapply(numeric_data, sd, na.rm = TRUE), 2),
  Min      = round(sapply(numeric_data, min, na.rm = TRUE), 2),
  Max      = round(sapply(numeric_data, max, na.rm = TRUE), 2)
)
```

```
kable(
  deskriptif,
  booktabs = TRUE,
  align     = "lrrrrr",
  linesep   = "",
  caption   = "Statistika Deskriptif Variabel Numerik"
) %>%
  kable_styling(
    font_size      = 8,
    latex_options = c("striped", "hold_position", "scale_down")
  )
```

```
kuartil_raw <- sapply(
  data %>% select(where(is.numeric), -tahun),
  quantile, na.rm = TRUE
)
```

```

# Transpose: variabel jadi baris, kuartil jadi kolom
kuartil_df <- as.data.frame(t(kuartil_raw))
colnames(kuartil_df) <- c("Min", "Q1 (25%)", "Median (50%)", "Q3 (75%)", "Max")

# Nama variabel dengan satuan
kuartil_df$Variabel <- c(
  "PDRB per Kapita (Rp juta)",
  "Kemiskinan (%)",
  "Pengangguran (%)",
  "IPM",
  "Harapan Hidup (Tahun)",
  "Rata-rata Lama Sekolah (Tahun)",
  "Akses Internet (%)",
  "Jalan Baik (%)",
  "Air Bersih (%)")
)

# Konversi PDRB ke juta
kuartil_df["pdrb_perkapita", c("Min", "Q1 (25%)", "Median (50%)", "Q3 (75%)", "Max")] <-
  round(kuartil_df["pdrb_perkapita", c("Min", "Q1 (25%)", "Median (50%)", "Q3 (75%)", "Max")] / 1e6, 2)

# Susun kolom: Variabel di depan
kuartil_df <- kuartil_df[, c("Variabel", "Min", "Q1 (25%)",
  "Median (50%)", "Q3 (75%)", "Max")]

knitr::kable(
  kuartil_df,
  digits = 2,
  caption = "Kuartil Variabel Numerik",
  booktabs = TRUE,
  row.names = FALSE,
  align = "lrrrrr"
) %>%
  kable_styling(
    latex_options = c("striped", "hold_position", "scale_down"),
    font_size = 9
  )
)

# Fungsi untuk menghitung modus
get_mode <- function(x) {
  tbl <- table(x)
  names(tbl)[which.max(tbl)]
}

cat("Modus variabel tahun:", get_mode(data$tahun), "\n")
cat("Modus variabel provinsi:", get_mode(data$provinsi), "\n")

```

A.4 Analisis Missing Value

```

missing_count <- colSums(is.na(data))
missing_df <- data.frame(

```



```

Variabel = names(missing_count),
Jumlah_NA = as.integer(missing_count),
Persentase = round(missing_count / nrow(data) * 100, 2)
)

knitr::kable(missing_df,
              caption = "Jumlah Missing Value per Variabel",
              booktabs = TRUE,
              row.names = FALSE) %>%
  kable_styling(latex_options = c("striped", "hold_position"),
                font_size = 10)

cat("Total baris dengan label 'Missing Value':", sum(data$catatan_data == "Missing Value"), "\n")
cat("Total sel (cell) yang NA:", sum(is.na(data)), "\n")

```

```

data_clean <- data

for(col in names(data_clean)){
  if(is.numeric(data_clean[[col]])){
    data_clean[[col]][is.na(data_clean[[col]])] <-
      median(data_clean[[col]], na.rm = TRUE)
  }
}

```

```

cat("Sisa missing value setelah imputasi:\n")
colSums(is.na(data_clean))

```

A.5 Analisis Outlier

```

detect_outlier <- function(x){
  Q1 <- quantile(x, 0.25, na.rm = TRUE)
  Q3 <- quantile(x, 0.75, na.rm = TRUE)
  IQR_val <- IQR(x, na.rm = TRUE)

  lower <- Q1 - 1.5 * IQR_val
  upper <- Q3 + 1.5 * IQR_val

  sum(x < lower | x > upper, na.rm = TRUE)
}

outlier_count <- sapply(data_clean[, sapply(data_clean, is.numeric)], detect_outlier)

outlier_df <- data.frame(
  Variabel = names(outlier_count),
  Jumlah_Outlier = as.integer(outlier_count)
)

knitr::kable(outlier_df,
              caption = "Jumlah Outlier per Variabel (Metode IQR)",
              booktabs = TRUE,
              row.names = FALSE) %>%

```

```
kable_styling(latex_options = c("striped", "hold_position"),
              font_size = 10)
```

```
outlier_rows <- data_clean[data_clean$catatan_data == "Outlier", ]
cat("Jumlah baris berlabel 'Outlier':", nrow(outlier_rows), "\n\n")
knitr::kable(outlier_rows[, c("wilayah", "provinsi", "tahun", "pdrb_perkapita",
                              "kemiskinan", "pengangguran", "akses_internet")],
              caption = "Baris Data yang Berlabel Outlier",
              booktabs = TRUE,
              row.names = FALSE,
              digits = 2) %>%
  kable_styling(latex_options = c("striped", "hold_position", "scale_down"),
                font_size = 8)
```

A.6 Visualisasi Data

```
ggplot(data_clean, aes(x = ipm)) +
  geom_histogram(bins = 25, fill = "#3498db", color = "white", alpha = 0.8) +
  labs(
    title = "Distribusi Indeks Pembangunan Manusia (IPM)",
    x = "Nilai IPM",
    y = "Frekuensi (Jumlah Wilayah)"
  ) +
  theme_minimal() +
  theme(plot.title = element_text(face = "bold", size = 14))
```

```
ggplot(data_clean, aes(y = kemiskinan)) +
  geom_boxplot(fill = "#e74c3c", alpha = 0.7, outlier.color = "darkred", outlier.size = 2) +
  labs(
    title = "Boxplot Tingkat Kemiskinan",
    y = "Tingkat Kemiskinan (%)"
  ) +
  theme_minimal() +
  theme(plot.title = element_text(face = "bold", size = 14))
```

```
ggplot(data_clean, aes(x = ipm, y = kemiskinan)) +
  geom_point(alpha = 0.3, color = "#2c3e50", size = 1.5) +
  geom_smooth(method = "lm", color = "#e74c3c", se = TRUE, linetype = "dashed") +
  labs(
    title = "Hubungan IPM dan Tingkat Kemiskinan",
    x = "Indeks Pembangunan Manusia (IPM)",
    y = "Tingkat Kemiskinan (%)"
  ) +
  theme_minimal() +
  theme(plot.title = element_text(face = "bold", size = 14))
```

```
ggplot(data_clean, aes(x = reorder(provinsi, provinsi, function(x) -length(x)))) +
  geom_bar(fill = "#27ae60", alpha = 0.8) +
  labs(
    title = "Jumlah Observasi per Provinsi",
```

```

  x = "Provinsi",
  y = "Jumlah Observasi"
) +
theme_minimal() +
theme(
  axis.text.x = element_text(angle = 45, hjust = 1, size = 9),
  plot.title = element_text(face = "bold", size = 14)
)

```

```

ggplot(data_clean, aes(x = pengangguran)) +
  geom_histogram(bins = 25, fill = "#f39c12", color = "white", alpha = 0.8) +
  labs(
    title = "Distribusi Tingkat Pengangguran",
    x = "Tingkat Pengangguran (%)",
    y = "Frekuensi (Jumlah Wilayah)"
  ) +
  theme_minimal() +
  theme(plot.title = element_text(face = "bold", size = 14))

```

```

num_cols <- data_clean[, apply(data_clean, is.numeric)]
corr_mat <- cor(num_cols)

corrplot(corr_mat,
  method = "color",
  type = "upper",
  tl.cex = 0.8,
  tl.col = "black",
  addCoef.col = "black",
  number.cex = 0.6,
  col = colorRampPalette(c("#e74c3c", "white", "#3498db"))(200),
  title = "Heatmap Korelasi Antar Variabel",
  mar = c(0, 0, 2, 0))

```

A.7 Probabilitas dan Distribusi

```

set.seed(123) # untuk reproducibility
shapiro_result <- shapiro.test(sample(data_clean$ipm, 500))
shapiro_result

```

```

if(shapiro_result$p.value < 0.05){
  cat("Keputusan: TOLAK H0 (p-value =", round(shapiro_result$p.value, 4), "< 0.05)\n")
  cat("Kesimpulan: Data IPM secara statistik TIDAK berdistribusi normal sempurna.\n")
} else {
  cat("Keputusan: GAGAL TOLAK H0 (p-value =", round(shapiro_result$p.value, 4), ">= 0.05)\n")
  cat("Kesimpulan: Tidak cukup bukti untuk menolak bahwa data IPM berdistribusi normal.\n")
}

```

```

mean_kemiskinan <- mean(data_clean$kemiskinan)
prob_kemiskinan <- mean(data_clean$kemiskinan > mean_kemiskinan)

```

```

cat("Rata-rata kemiskinan:", round(mean_kemiskinan, 2), "%\n")
cat("P(kemiskinan > rata-rata) =", round(prob_kemiskinan, 4), "%\n")
cat("Artinya:", round(prob_kemiskinan * 100, 1), "% wilayah memiliki kemiskinan di atas rata-rata.\n")

prob_ipm <- mean(data_clean$ipm > 75)

cat("P(IPM > 75) =", round(prob_ipm, 4), "%\n")
cat("Artinya:", round(prob_ipm * 100, 1), "% wilayah memiliki IPM di atas 75 (kategori tinggi).\n")

prob_pengangguran <- mean(data_clean$pengangguran > 10)

cat("P(pengangguran > 10%) =", round(prob_pengangguran, 4), "%\n")
cat("Artinya:", round(prob_pengangguran * 100, 1), "% wilayah memiliki pengangguran di atas 10%.\n")

# Menggunakan distribusi normal untuk IPM
mean_ipm <- mean(data_clean$ipm)
sd_ipm <- sd(data_clean$ipm)

# P(IPM > 80) menggunakan distribusi normal
prob_ipm_80 <- 1 - pnorm(80, mean = mean_ipm, sd = sd_ipm)
cat("Berdasarkan distribusi normal:\n")
cat("P(IPM > 80) =", round(prob_ipm_80, 4), "%\n")

# Nilai IPM pada persentil ke-90 (qnorm)
ipm_p90 <- qnorm(0.90, mean = mean_ipm, sd = sd_ipm)
cat("Nilai IPM pada persentil ke-90:", round(ipm_p90, 2), "%\n")

```

A.8 Analisis Korelasi

```

corr_matrix <- cor(data_clean[, sapply(data_clean, is.numeric)])

# Hapus tahun dari matriks
corr_matrix <- corr_matrix[
  !rownames(corr_matrix) %in% "tahun",
  !colnames(corr_matrix) %in% "tahun"
]

# Nama baris dan kolom yang rapi dengan satuan
nama_rapi <- c(
  "PDRB per Kapita (Rp juta)",
  "Kemiskinan (%)",
  "Pengangguran (%)",
  "IPM",
  "Harapan Hidup (Thn)",
  "Lama Sekolah (Thn)",
  "Akses Internet (%)",
  "Jalan Baik (%)",
  "Air Bersih (%)"
)
rownames(corr_matrix) <- nama_rapi

```

```

colnames(corr_matrix) <- c("PDRB", "Miskin", "Nganggur", "IPM",
                           "Harapan", "Sekolah", "Internet", "Jalan", "Air")

knitr::kable(
  round(corr_matrix, 3),
  caption = "Matriks Korelasi Antar Variabel Numerik",
  booktabs = TRUE,
  align    = paste(rep("r", 9), collapse = "")
) %>%
  kable_styling(
    latex_options = c("striped", "scale_down"),
    font_size     = 8,
    full_width    = FALSE
  ) %>%
  landscape()

```

```

cor_test_1 <- cor.test(data_clean$ipm, data_clean$kemiskinan)
cor_test_1

```

```

cor_test_2 <- cor.test(data_clean$ipm, data_clean$akses_internet)
cor_test_2

```

```

cor_test_3 <- cor.test(data_clean$pdrb_perkapita, data_clean$kemiskinan)
cor_test_3

```