

Analisis Data Pembangunan Wilayah Indonesia

Proyek Akhir Probabilitas dan Statistika

Tim Kelompok

2026-06-04

Section 1

Tujuan Analisis

Tujuan

- Memahami karakteristik data pembangunan wilayah Indonesia
- Mengidentifikasi missing value dan outlier
- Melakukan analisis statistika deskriptif
- Menganalisis distribusi dan probabilitas data
- Mengidentifikasi hubungan antar variabel

Section 2

Dataset

Informasi Dataset

- Jumlah observasi : **2500**
- Jumlah variabel : **13**
- Periode : **2020–2024**
- Cakupan : **10 provinsi**

Struktur Variabel

```
struktur_df <- data.frame(
  Variabel = names(data),
  Tipe = sapply(data, class)
)

kable(
  struktur_df,
  booktabs = TRUE
) %>%
  kable_styling(font_size = 8)
```

	Variabel	Tipe
wilayah	wilayah	character
provinsi	provinsi	character
tahun	tahun	integer
pdrb_perkapita	pdrb_perkapita	numeric
kemiskinan	kemiskinan	numeric

Section 3

Statistika Deskriptif

Ringkasan Statistik

```
numeric_data <- data %>%  
  select(where(is.numeric))  
  
deskriptif <- data.frame(  
  Variabel = names(numeric_data),  
  Mean = round(  
    sapply(numeric_data, mean, na.rm = TRUE),  
    2  
  ),  
  SD = round(  
    sapply(numeric_data, sd, na.rm = TRUE),  
    2  
  ),  
  Min = round(  
    sapply(numeric_data, min, na.rm = TRUE),  
    2  
  )  
)
```

Temuan Utama

- PDRB per kapita memiliki variasi paling tinggi.
- Selisih mean dan median yang besar mengindikasikan adanya outlier.
- IPM relatif tinggi dibanding indikator lainnya.
- Kemiskinan dan pengangguran menunjukkan distribusi menceng ke kanan.

Section 4

Missing Value dan Outlier

Missing Value

```
missing_count <- colSums(is.na(data))

missing_df <- data.frame(
  Variabel = names(missing_count),
  Jumlah_NA = as.integer(missing_count),
  Persentase = round(
    missing_count / nrow(data) * 100,
    2
  )
)

missing_df <- missing_df %>%
  filter(Jumlah_NA > 0)

kable(
  missing_df,
```

Penanganan Missing Value

Menggunakan **median imputation** karena:

- Robust terhadap outlier
- Tidak terlalu dipengaruhi distribusi menceng
- Cocok untuk proporsi missing value kecil

Deteksi Outlier (IQR)

```

detect_outlier <- function(x){

  Q1 <- quantile(x, 0.25, na.rm = TRUE)
  Q3 <- quantile(x, 0.75, na.rm = TRUE)

  IQR_val <- IQR(x, na.rm = TRUE)

  sum(
    x < Q1 - 1.5 * IQR_val |
    x > Q3 + 1.5 * IQR_val,
    na.rm = TRUE
  )
}

outlier_count <- sapply(
  data_clean[, sapply(data_clean, is.numeric)],

```


Interpretasi

- PDRB per kapita memiliki outlier paling ekstrem.
- Outlier dapat memengaruhi mean dan varians.
- Median lebih representatif dibanding mean pada distribusi yang menceng.

Section 5

Visualisasi Data


Distribusi IPM

```
ggplot(data_clean, aes(x = ipm)) +  
  geom_histogram(  
    bins = 25,  
    fill = "#3498db",  
    color = "white"  
  ) +  
  labs(  
    title = "Distribusi IPM",  
    x = "IPM",  
    y = "Frekuensi"  
  ) +  
  theme_minimal()
```



Boxplot Kemiskinan

```
ggplot(data_clean, aes(y = kemiskinan)) +  
  geom_boxplot(  
    fill = "#e74c3c",  
    alpha = 0.8  
  ) +  
  labs(  
    title = "Boxplot Kemiskinan",  
    y = "Kemiskinan (%)"  
  ) +  
  theme_minimal()
```



Hubungan IPM dan Kemiskinan

```
ggplot(  
  data_clean,  
  aes(  
    x = ipm,  
    y = kemiskinan  
  )  
) +  
  geom_point(  
    alpha = 0.3  
  ) +  
  geom_smooth(  
    method = "lm",  
    color = "red",  
    se = TRUE  
  ) +  
  labs(  
    title = "Hubungan IPM dan Kemiskinan"  
  )
```


Observasi per Provinsi

```
ggplot(  
  data_clean,  
  aes(x = provinsi)  
) +  
  geom_bar(fill = "#27ae60") +  
  labs(  
    title = "Jumlah Observasi per Provinsi",  
    x = "Provinsi",  
    y = "Jumlah Observasi"  
) +  
  theme_minimal() +  
  theme(  
    axis.text.x = element_text(  
      angle = 45,  
      hjust = 1  
    )  
  )
```

Heatmap Korelasi

```
num_cols <- data_clean %>%
  select(where(is.numeric))
```

```
corrplot(
  cor(num_cols),
  method = "color",
  type = "upper",
  addCoef.col = "black",
  number.cex = 0.5,
  tl.cex = 0.7
)
```



Section 6

Probabilitas dan Distribusi

Uji Normalitas IPM

Hipotesis:

- H_0 : Data berdistribusi normal
- H_a : Data tidak berdistribusi normal

```
set.seed(123)
```

```
shapiro_result <- shapiro.test(  
  sample(  
    data_clean$ipm,  
    500  
  )  
)
```

```
hasil_shapiro <- data.frame(  
  Statistik = round(shapiro_result$statistic, 4),  
  P_Value = round(shapiro_result$p.value, 4)
```

Probabilitas Empiris

```
mean_kemiskinan <- mean(data_clean$kemiskinan)
```

```
prob_kemiskinan <- mean(  
  data_clean$kemiskinan >  
    mean_kemiskinan  
)
```

```
prob_ipm <- mean(  
  data_clean$ipm > 75  
)
```

```
prob_pengangguran <- mean(  
  data_clean$pengangguran > 10  
)
```

```
hasil_prob <- data.frame(  

```

Distribusi Normal IPM

```
mean_ipm <- mean(data_clean$ipm)
sd_ipm <- sd(data_clean$ipm)
```

```
prob_ipm_80 <- 1 -
  pnorm(
    80,
    mean = mean_ipm,
    sd = sd_ipm
  )
```

```
ipm_p90 <- qnorm(
  0.90,
  mean = mean_ipm,
  sd = sd_ipm
)
```


Section 7

Analisis Korelasi

Uji Korelasi Pearson

```
cor_test_1 <- cor.test(  
  data_clean$ipm,  
  data_clean$kemiskinan  
)  
  
cor_test_2 <- cor.test(  
  data_clean$ipm,  
  data_clean$akses_internet  
)  
  
cor_test_3 <- cor.test(  
  data_clean$pdrb_perkapita,  
  data_clean$kemiskinan  
)  
  
hasil <- data.frame(  

```


Section 8

Kesimpulan

Temuan Utama

Aspek	Temuan
IPM	Sebagian besar wilayah berada pada kategori sedang hingga tinggi
Kemiskinan	Masih terdapat wilayah dengan tingkat kemiskinan tinggi
Pengangguran	Sebaran relatif merata dengan beberapa outlier
PDRB	Menunjukkan ketimpangan ekonomi yang cukup besar
Infrastruktur	Akses internet dan air bersih belum merata

Rekomendasi

- 1 Prioritaskan pembangunan wilayah dengan IPM rendah.
- 2 Tingkatkan akses pendidikan dan kesehatan.
- 3 Perluas infrastruktur digital pada wilayah tertinggal.
- 4 Tingkatkan program pengentasan kemiskinan.
- 5 Perbaiki kualitas pengumpulan data untuk mengurangi missing value.

Section 9

Referensi

Referensi

- Walpole et al. (2012). *Probability and Statistics for Engineers and Scientists*.
- Field (2013). *Discovering Statistics Using R*.
- Wickham (2016). *ggplot2: Elegant Graphics for Data Analysis*.
- BPS (2023). *Indeks Pembangunan Manusia Indonesia*.
- James et al. (2013). *An Introduction to Statistical Learning with Applications in R*.