

Analisis Data Pembangunan Wilayah Indonesia

Proyek Akhir Probabilitas dan Statistika

Kelompok 6

2026-06-07

Section 1

Anggota Kelompok

Anggota Kelompok

- Azzura Mori - J0403251074
- Azhar Fawwaz Haris - J0403251043
- Ayyash Syauqi Syahadah - J0403251100
- Fuad Nizard Attaqi - J0403251086
- Haidar Hafizh Izzuddin - J0403251031
- Muhammad Adiyoga Danendra - J0403251063

Section 2

Tujuan Analisis

Tujuan

- Memahami karakteristik data pembangunan wilayah Indonesia
- Mengidentifikasi missing value dan outlier
- Melakukan analisis statistika deskriptif
- Menganalisis distribusi dan probabilitas data
- Mengidentifikasi hubungan antar variabel

Section 3

Dataset

Informasi Dataset

- Jumlah observasi : **2500**
- Jumlah variabel : **13**
- Periode : **2020–2024**
- Cakupan : **10 provinsi**

Kode: Membaca Dataset

```
library(ggplot2)
library(dplyr)
library(corrplot)

data <- read.csv(
  "Dataset/pembangunan_wilayah_missing_outlier.csv"
)
data$tahun_factor <- as.factor(data$tahun)

# Cek struktur dan dimensi
str(data)
dim(data)
head(data)
```

Struktur Variabel

	Variabel	Tipe
wilayah	wilayah	character
provinsi	provinsi	character
tahun	tahun	integer
pdrb_perkapita	pdrb_perkapita	numeric
kemiskinan	kemiskinan	numeric
pengangguran	pengangguran	numeric
ipm	ipm	numeric
harapan_hidup	harapan_hidup	numeric
rata_lama_sekolah	rata_lama_sekolah	numeric
akses_internet	akses_internet	numeric
jalan_baik	jalan_baik	numeric
air_bersih	air_bersih	numeric
catatan_data	catatan_data	character
tahun_factor	tahun_factor	factor

Section 4

Statistika Deskriptif

Kode: Statistika Deskriptif

```
numeric_data <- data %>%  
  select(where(is.numeric), -tahun)  
  
deskriptif <- data.frame(  
  Mean      = sapply(numeric_data, mean,   na.rm=TRUE),  
  Median    = sapply(numeric_data, median, na.rm=TRUE),  
  SD        = sapply(numeric_data, sd,     na.rm=TRUE),  
  Variance  = sapply(numeric_data, var,    na.rm=TRUE),  
  Minimum   = sapply(numeric_data, min,    na.rm=TRUE),  
  Maximum   = sapply(numeric_data, max,    na.rm=TRUE)  
)  
  
print(deskriptif)  
  
# Kuartil  
sapply(numeric_data, quantile, na.rm = TRUE)
```

Ringkasan Statistik

	Variabel	Mean	Median	SD	Min	Max
tahun	tahun	2022.00	2022.00	1.43	2020.00	2.024000e+03
pdrb_perkapita	pdrb_perkapita	135650462.48	137310624.00	89341269.95	15031581.00	1.774545e+09
kemiskinan	kemiskinan	13.72	13.72	6.89	2.01	6.753000e+01
pengangguran	pengangguran	8.05	8.23	4.26	1.01	4.704000e+01
ipm	ipm	69.90	69.89	8.54	55.01	8.499000e+01
harapan_hidup	harapan_hidup	69.13	69.30	5.17	60.01	7.799000e+01
rata_lama_sekolah	rata_lama_sekolah	9.58	9.52	2.63	5.02	1.400000e+01
akses_internet	akses_internet	58.79	58.09	22.82	0.01	9.799000e+01
jalan_baik	jalan_baik	65.26	65.02	20.37	30.01	9.995000e+01
air_bersih	air_bersih	69.76	69.68	17.50	40.03	9.999000e+01

Temuan Utama

- PDRB per kapita memiliki variasi paling tinggi
- Selisih mean dan median yang besar mengindikasikan adanya outlier
- IPM relatif tinggi dibanding indikator lainnya
- Kemiskinan dan pengangguran menunjukkan distribusi menceng ke kanan

Section 5

Missing Value dan Outlier

Kode: Identifikasi Missing Value

```
# Hitung jumlah missing per kolom
missing_count <- colSums(is.na(data))
print(missing_count)

# Median Imputation
data_clean <- data
for(col in names(data_clean)){
  if(is.numeric(data_clean[[col]])){
    data_clean[[col]][is.na(data_clean[[col]])] <-
      median(data_clean[[col]], na.rm = TRUE)
  }
}

# Verifikasi: semua NA sudah terimputasi
colSums(is.na(data_clean))
```

Missing Value

	Variabel	Jumlah_NA	Persentase
pdrb_perkapita	pdrb_perkapita	25	1.00
kemiskinan	kemiskinan	24	0.96
pengangguran	pengangguran	25	1.00
ipm	ipm	25	1.00
akses_internet	akses_internet	25	1.00
jalan_baik	jalan_baik	25	1.00

Penanganan Missing Value

Menggunakan **median imputation** karena:

- Robust terhadap outlier
- Tidak terlalu dipengaruhi distribusi menceng
- Cocok untuk proporsi missing value kecil

Kode: Deteksi Outlier (IQR)

```
detect_outlier <- function(x){  
  Q1      <- quantile(x, 0.25, na.rm = TRUE)  
  Q3      <- quantile(x, 0.75, na.rm = TRUE)  
  IQR_val <- IQR(x, na.rm = TRUE)  
  
  lower <- Q1 - 1.5 * IQR_val  
  upper <- Q3 + 1.5 * IQR_val  
  
  sum(x < lower | x > upper, na.rm = TRUE)  
}  
  
outlier_count <- sapply(  
  data_clean[, sapply(data_clean, is.numeric)],  
  detect_outlier  
)
```

Deteksi Outlier (IQR)

	Variabel	Outlier	Persentase
tahun	tahun	0	0.0
pdrb_perkapita	pdrb_perkapita	5	0.2
kemiskinan	kemiskinan	5	0.2
pengangguran	pengangguran	5	0.2
ipm	ipm	0	0.0
harapan_hidup	harapan_hidup	0	0.0
rata_lama_sekolah	rata_lama_sekolah	0	0.0
akses_internet	akses_internet	0	0.0
jalan_baik	jalan_baik	0	0.0
air_bersih	air_bersih	0	0.0

Interpretasi Outlier

- PDRB per kapita memiliki outlier paling ekstrem
- Outlier dapat memengaruhi mean dan varians
- Median lebih representatif dibanding mean pada distribusi menceng

Section 6

Visualisasi Data

Kode: Histogram & Boxplot


Histogram IPM

```
ggplot(data_clean, aes(x = ipm)) +  
  geom_histogram(bins = 20, fill = "#3498db",  
                 color = "white", alpha = 0.8) +  
  labs(title = "Kurva Distribusi Empiris IPM Wilayah",  
        x = "Skor IPM", y = "Frekuensi") +  
  theme_minimal()
```

Boxplot Kemiskinan


```
ggplot(data_clean, aes(y = kemiskinan)) +  
  geom_boxplot(fill = "#e74c3c",  
               color = "#c0392b", alpha = 0.7) +  
  labs(title = "Boxplot Tingkat Kemiskinan",  
        y = "Persentase (%)") +  
  theme_minimal()
```

Distribusi IPM



Mayoritas wilayah memiliki IPM pada kategori sedang hingga tinggi.

Boxplot Kemiskinan



Terlihat adanya beberapa nilai ekstrem pada tingkat kemiskinan.

Kode: Scatter Plot & Bar Chart


Scatter Plot IPM vs Kemiskinan

```
ggplot(data_clean, aes(x = ipm, y = kemiskinan)) +  
  geom_point(alpha = 0.4, color = "#2c3e50") +  
  geom_smooth(method = "lm", color = "#27ae60",  
              se = TRUE, linetype = "dashed") +  
  labs(title = "Scatter Plot: IPM vs Kemiskinan",  
        x = "IPM", y = "Kemiskinan (%)") +  
  theme_minimal()
```

Bar Chart per Provinsi


```
ggplot(data_clean, aes(x = provinsi)) +  
  geom_bar(fill = "#27ae60", alpha = 0.8) +  
  theme_minimal() +  
  theme(axis.text.x = element_text(angle = 45, hjust = 1)) +  
  labs(title = "Observasi per Provinsi",  
        x = "Provinsi", y = "Jumlah Baris")
```

Hubungan IPM dan Kemiskinan




Secara teori, hubungan yang diharapkan bersifat negatif.

Distribusi Pengangguran



Distribusi pengangguran menceng ke kanan dengan beberapa outlier.

Observasi per Provinsi




Dataset relatif seimbang antar provinsi.

Kode: Heatmap Korelasi

```
kontinu_cols <- c("pdrb_perkapita", "kemiskinan",  
                  "pengangguran", "ipm", "harapan_hidup",  
                  "rata_lama_sekolah", "akses_internet",  
                  "jalan_baik", "air_bersih")  
  
matriks_korelasi <- cor(data_clean[kontinu_cols])  
  
corrplot(matriks_korelasi,  
          method = "color",  
          type    = "upper",  
          tl.col  = "black",  
          tl.cex  = 0.8)
```

Heatmap Korelasi



Section 7

Probabilitas dan Distribusi

Kode: Uji Normalitas

```
# Uji Shapiro-Wilk (sampel 500 observasi)  
set.seed(123)  
shapiro.test(sample(data_clean$ipm, 500))
```

```
# Probabilitas Empiris
```

```
mean_kemiskinan <- mean(data_clean$kemiskinan)  
prob_kemiskinan <- mean(  
  data_clean$kemiskinan > mean_kemiskinan)  
prob_ipm <- mean(data_clean$ipm > 75)  
prob_pengangguran <- mean(data_clean$pengangguran > 10)  
  
cat("P(Kemiskinan > mean) :", prob_kemiskinan, "\n")  
cat("P(IPM > 75) :", prob_ipm, "\n")  
cat("P(Pengangguran > 10) :", prob_pengangguran, "\n")
```

Uji Normalitas IPM

Hipotesis uji Shapiro-Wilk:

- H_0 : Data IPM berdistribusi normal
- H_1 : Data IPM tidak berdistribusi normal

	Statistik	P_Value
W	0.9572	0

Jika p-value < 0.05 maka H_0 ditolak.

Probabilitas Empiris

Kejadian	Probabilitas (\%)
Kemiskinan > Rata-rata	49.44
IPM > 75	31.88
Pengangguran > 10\%	36.20

Kode: Distribusi Normal IPM

```
mean_ipm <- mean(data_clean$ipm)
sd_ipm    <- sd(data_clean$ipm)

# Probabilitas IPM > 80
prob_ipm_80 <- 1 - pnorm(80,
                          mean = mean_ipm,
                          sd    = sd_ipm)

# Nilai IPM pada persentil ke-90
ipm_p90 <- qnorm(0.90,
                 mean = mean_ipm,
                 sd    = sd_ipm)

cat("P(IPM > 80)      :", round(prob_ipm_80 * 100, 2), "%\n")
cat("Persentil ke-90 :", round(ipm_p90, 2), "\n")
```

Distribusi Normal IPM

Ukuran	Nilai
$P(\text{IPM} > 80)$	11.72
Persentil ke-90	80.78

Section 8

Analisis Korelasi

Kode: Matriks & Uji Korelasi

```
# Matriks korelasi seluruh variabel numerik
corr_matrix <- cor(
  data_clean[, sapply(data_clean, is.numeric)]
)
print(corr_matrix)
```

```
# Uji Korelasi Pearson
cor.test(data_clean$ipm,
  data_clean$kemiskinan)

cor.test(data_clean$ipm,
  data_clean$akses_internet)

cor.test(data_clean$pdrb_perkapita,
  data_clean$kemiskinan)
```

Uji Korelasi Pearson

Pasangan	Korelasi	P_Value
IPM vs Kemiskinan	0.020	0.327
IPM vs Internet	0.002	0.916
PDRB vs Kemiskinan	-0.005	0.815

Interpretasi Kekuatan Korelasi

Nilai $ r $	Kekuatan
0.00 – 0.19	Sangat lemah
0.20 – 0.39	Lemah
0.40 – 0.59	Sedang
0.60 – 0.79	Kuat
0.80 – 1.00	Sangat kuat

Section 9

Kesimpulan

Temuan Utama

Aspek	Temuan
IPM	Sebagian besar wilayah pada kategori sedang–tinggi
Kemiskinan	Masih terdapat wilayah dengan kemiskinan tinggi
Pengangguran	Sebaran merata dengan beberapa outlier
PDRB	Ketimpangan ekonomi cukup besar
Infrastruktur	Akses internet dan air bersih belum merata

Rekomendasi

- 1 Prioritaskan pembangunan wilayah dengan IPM rendah
- 2 Tingkatkan akses pendidikan dan kesehatan
- 3 Perluas infrastruktur digital pada wilayah tertinggal
- 4 Tingkatkan program pengentasan kemiskinan
- 5 Perbaiki kualitas pengumpulan data untuk mengurangi missing value

Section 10

Referensi

Referensi

- Walpole et al. (2012). *Probability and Statistics for Engineers and Scientists*
- Field (2013). *Discovering Statistics Using R*
- Wickham (2016). *ggplot2: Elegant Graphics for Data Analysis*
- BPS (2023). *Indeks Pembangunan Manusia Indonesia*
- James et al. (2013). *An Introduction to Statistical Learning with Applications in R*